

Optimisation des trajets d'un chauffeur Yango ou Uber Par reinforcement learning

Q-Learning and Deep Q-Networks Comparison

Projet de Reinforcement Learning
Août 2026

Préparé Par :

#	Noms
1	CHRISTIAN Kossi
2	SERGEO SELAGSA Moffo
3	IDRISSA SEYDOU Gueye
4	ZANA BABA STÉPHANE Coulibaly

Résumé exécutif

Ce projet compare deux algorithmes de Reinforcement Learning pour optimiser le repositionnement des chauffeurs de ride-sharing. Les résultats montrent que Q-Learning surpasse DQN de 17.3% sur ce problème de petite taille d'espace d'état (25 zones). L'étude démontre l'importance de choisir l'algorithme approprié en fonction de la taille du problème. Le code complet, les données expérimentales et les visualisations sont disponibles sur GitHub.

1. Introduction

Le Reinforcement Learning (RL) est un paradigme d'apprentissage où un agent apprend à prendre des décisions optimales en interagissant avec un environnement. Contrairement à l'apprentissage supervisé, l'agent reçoit des signaux de récompense/pénalité plutôt que des labels directs.

Dans le contexte des plateformes de ride-sharing (Yango, Uber, Bolt), les chauffeurs doivent continuellement décider vers quelle zone se repositionner après avoir complété une course. Cette décision impacte directement leur revenu, le temps d'attente, et la satisfaction client.

Ce projet applique deux algorithmes RL majeurs - Q-Learning et DQN - pour apprendre une stratégie optimale de repositionnement dans une simulation d'environnement urbain.

Objectifs

- Implémenter un environnement de simulation réaliste avec Gymnasium
- Entraîner un agent Q-Learning sur cet environnement
- Entraîner un agent DQN comme comparaison
- Analyser les résultats et identifier quel algorithme fonctionne mieux
- Tirer des leçons sur le choix algorithmique selon la taille du problème

2. Problème et contexte

Après avoir complété une course, un chauffeur doit décider vers quelle zone se déplacer.

Cette décision est basée typiquement sur l'expérience personnelle, des heuristiques simples, ou des données empiriques incomplètes.

Ces approches ne sont pas optimales car elles ne tiennent pas compte des variations horaires, des variations jour/semaine, de la distance de repositionnement, et des opportunités de trajets lucratifs.

Impact économique

Une mauvaise décision de repositionnement peut coûter cher : temps d'attente inutile, coûts de carburant, perte d'opportunités. Optimiser cette décision peut augmenter les revenus de 10-20% par chauffeur.

3. État de l'art

3.1 Q-Learning

Q-Learning est un algorithme model-free qui apprend une fonction $Q(s,a)$ tabulaire. Avantages : convergence garantie, interprétabilité, efficient pour petits espaces. Limitations : croissance exponentielle avec la taille d'état, pas de généralisation entre états similaires.

3.2 Deep Q-Networks (DQN)

DQN remplace la Q-table par un réseau de neurones pour approximer $Q(s,a)$. Avantages : scalable à grands espaces, généralise entre états. Limitations : convergence non garantie, plus de hyperparamètres.

4. Formulation MDP

4.1 Espace d'état (S)

État : $[x, y, \text{hour}, \text{day}, \text{idle_time}]$

- $x \in [0, 5]$: Position X
- $y \in [0, 5]$: Position Y
- $\text{hour} \in [0, 24]$: Heure
- $\text{day} \in [0, 7]$: Jour
- $\text{idle_time} \in [0, 1000]$: Attente

4.2 Espace d'action (A)

Discret : 25 actions (move to zone 0, 1, ..., 24) sur grille 5×5

4.3 Fonction de récompense (R)

$r(s, a) = \text{trip_fare} - \text{repositioning_cost}$

5. Environnement de simulation

Implémenté avec Gymnasium avec patterns horaires réalistes : pic matin (6-9h) 1.5×, midi (12-14h) 1.2×, pic soir (17-20h) 1.8×, nuit (22-6h) 0.3×, weekend -20%.




Figure 1: Grille urbaine 5×5 avec heatmap de demande par zone

6. Implémentation Q-Learning

6.1 Algorithme

Formule : $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$

Hyperparamètres : $\alpha=0.1$ (taux d'apprentissage), $\gamma=0.99$ (discount factor), $\epsilon=0.1$ (exploration)

6.2 Résultats

Q-table : 7,459 états explorés | Convergence : très rapide | Reward moyen : 1,774,459 | Trips : 545.5 (54.5%)




Figure 2: Courbes d'entraînement Q-Learning (500 épisodes)

7. Implémentation DQN

7.1 Architecture

Input (5) $\rightarrow$ Dense(128) $\rightarrow$ ReLU $\rightarrow$ Dense(128) $\rightarrow$ ReLU $\rightarrow$ Output(25)

Experience replay : buffer 10,000, batch 32, loss MSE, optimizer Adam (lr=0.001)

7.2 Résultats

Convergence : plus lente | Reward moyen : 1,467,003 (-17.3% vs Q-Learning) | Trips : 453.4 (45.3%)




Figure 3: Courbes d'entraînement DQN (500 épisodes)

8. Résultats de performance

Comparaison Globale

Métrique	Q-Learning	DQN	Random
Avg Reward	1,774,459	1,467,003	1,567,413
Avg Trips	545.5	453.4	482.2
Success Rate	54.5%	45.3%	48.2%




Figure 4: Comparaison côte à côte Q-Learning vs DQN vs Random

9. Analyse des résultats

9.1 Pourquoi Q-Learning gagne (+17.3%)

- Espace petit (25 zones) → Q-Learning optimal sans approximation réseau
- Convergence rapide → tabular methods ont convergence garantie
- Moins de variance → estimateurs directs vs erreurs réseau

9.2 Performance vs baseline

- Q-Learning : +12.4% vs random
- DQN : -6.4% vs random (overkill pour petit problème)

Leçon : algorithme doit matcher la taille du problème




Figure 5: Trajectoire du Q-Learning agent sur 100 steps

10. Insights et apprentissages

Principes RL clés

Exploration vs exploitation : balance critique pour convergence

Reward shaping : récompense bien définie → apprentissage rapide

Algorithme choice : crucial selon la taille de l'espace d'état

11. Limitations et travail futur

Limitations actuelles

- Données synthétiques (pas données réelles)
- Agent mono-chauffeur (pas de compétition)
- Action space discret (chauffeurs réels : continu)

Travail futur

- Algorithmes avancés : Actor-Critic, Policy gradients
- Données réelles : historique Yango/Uber
- Multi-agent : compétition chauffeurs

12. Conclusion

Ce projet démontre l'application pratique du Reinforcement Learning à l'optimisation de repositionnement de chauffeurs.

Résultats clés

- ✓ Q-Learning surpasse DQN de 17.3%
- ✓ Q-Learning : convergence rapide et stable
- ✓ DQN : mauvais pour petits espaces
- ✓ Tous deux dépassent baseline aléatoire

Impact potentiel

Implémentation réelle : +10-20% revenus chauffeurs via repositionnement optimal

13. Références

- Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction (2nd ed.). MIT press.
- Mnih, V., et al. (2013). Playing Atari with deep reinforcement learning. arXiv preprint arXiv:1312.5602.
- Gymnasium: <https://gymnasium.farama.org/>
- PyTorch: <https://pytorch.org/>
- Streamlit: <https://streamlit.io/>
- GitHub: <https://github.com/kossichris/yango-rl>